

A. Rappels Monte Carlo

Soit $X_i \in \{0, 1\}$

$X = (X_1, \dots, X_p)$ de dimension p .

$$E(f(X)) = \sum_{x_i} f(x) P(X=x)$$

$$= \sum_{x_i} f(x_1, \dots, x_p) \cdot P(X = (x_1, \dots, x_p))$$

$$f: \mathbb{R}^p \rightarrow \mathbb{R}$$


\Rightarrow somme sur 2^p termes

Méthode de MC: $X^{(j)} \sim p(x)$

$$\text{Alors } \frac{1}{n} \sum_{j=1}^n f(X^{(j)}) \xrightarrow[n \rightarrow 100]{P.S.} E(f(X))$$

(LGN)

Comment obtenir les $X^{(j)}$?



\rightarrow tirage direct impossible.

Échantillonneur de Gibbs

(2)

Supposons que l'on connaisse $p(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p)$
 $\forall i$

Algorithme :

Initialisation : $x^{(0)} \sim q(x)$ (ex $q(x) = \prod_{i=1}^p q(x_i)$)

Pour $p = 1 \dots L$

$$q(x_{i=1}) = 1/2$$

$$x_1^{(p)} \sim p(x_1 | x_2^{(p-1)}, \dots, x_p^{(p-1)})$$

⋮

$$x_i^{(p)} \sim p(x_i | x_1^{(p)}, \dots, x_{i-1}^{(p)}, x_{i+1}^{(p-1)}, \dots, x_p^{(p-1)})$$

⋮

$$x_p^{(p)} \sim p(x_p | x_1^{(p)}, \dots, x_{p-1}^{(p)})$$

fin

$$\Rightarrow \left\| \frac{1}{L} \sum_{i=1}^L f(x^{(i)}) \right\| \xrightarrow[n \rightarrow \infty]{\text{p.s.}^?} E(f(x))$$

③ Restricted Boltzmann Machines

3

Soient $V_i \in \{0, 1\} \quad 1 \leq i \leq p$

$H_j \in \{0, 1\} \quad 1 \leq j \leq q$

Def

$$p(v, h) = \frac{1}{Z} e^{-E(v, h)}$$

$$\text{ou } E(v, h) = - \sum_{i=1}^p a_i v_i - \sum_{j=1}^q b_j h_j$$

$$- \sum_{i,j} w_{ij} v_i h_j$$

$$Z = \sum_{v, h} e^{-E(v, h)}$$

$$p(v) = \sum_h p(v, h)$$

Un RBM est caractérisé par :

$$\Theta = (a_i, b_j, w_{ij}) \text{ et par } q$$

Propriétés :

$$p(h|v) = \frac{p(v, h)}{p(v)} = \frac{p(v, h)}{\sum_h p(v, h)}$$

(4)

$$= \frac{e^{-E(v, h)}}{\sum_h e^{-E(v, h)}}$$

$$= \frac{e^{-\sum_i a_i v_i} \cdot e^{\sum_j b_j h_j + \sum_{i,j} w_{ij} v_i h_j}}{e^{-\sum_i a_i v_i} \sum_h e^{\sum_j b_j h_j + \sum_{i,j} w_{ij} v_i h_j}}$$

$$= \frac{\prod_j e^{b_j h_j + \sum_i w_{ij} v_i h_j}}{\sum_h \prod_j e^{b_j h_j + \sum_i w_{ij} v_i h_j}}$$

$$\sum_h \prod_j e^{b_j h_j + \sum_i w_{ij} v_i h_j}$$

$$= \prod_j e^{b_j h_j + \sum_i w_{ij} v_i h_j}$$

$$\prod_j \sum_{h_j} e^{b_j h_j + \sum_i w_{ij} v_i h_j}$$

$$= \frac{\prod_{j=1}^q}{\prod_{j=1}^q} \frac{e^{b_j h_j + \sum_i w_{ij} v_i h_j}}{1 + e^{b_j + \sum_i w_{ij} v_i}}$$

$$= \prod_{j=1}^q g(h_j)$$

$$\text{so } g(h_j = 1) = \frac{1}{1 + e^{-(b_j + \sum_i w_{ij} v_i)}}$$

$$= \text{sigmoid}(b_j + \sum_i w_{ij} v_i)$$

$$\Rightarrow p(h|v) = \frac{1}{\pi} \prod_{j=1}^q p(h_j | v)$$

(5)


$$\text{ou } p(h_j = 1 | v) = \text{sign}(b_j + \sum_i w_{ij} v_i)$$

\Rightarrow Cond à $V=v$, H sont indépendants.

$$\text{De même } p(v|h) = \frac{1}{\pi} \prod_{i=1}^p p(v_i | h)$$

$$\text{ou } p(v_i = 1 | h) = \text{sign}(a_i + \sum_j w_{ij} h_j)$$

\Rightarrow Représentation graphique d'un RBN:



\Rightarrow 1 réseau de neurones probabiliste à 1 couche

Applications

[LOTR, Retour vers le futur, Bridget Joneses, Titanic, Star Wars, Twilight]

$$u_1 = [1 \ 1 \ 0 \ 0 \ 1 \ 0] \rightarrow$$

$$u_2 = [0 \ 0 \ 1 \ 1 \ 0 \ 1]$$

$$u_3 = [0 \ 0 \ 1 \ 0 \ 0 \ 1]$$

$$u_4 = [0 \ 0 \ 0 \ 0 \ 0 \ 0]$$

$$u_5 = [1 \ 1 \ 1 \ 1 \ 1 \ 1]$$

Sentimental, cinéphile, Cinéphobe, Geek

• Réduction de dimension

• Générer des datas.

Tirer $p(v)$?

on a $\left\{ \begin{array}{l} p(v|h) \rightarrow \text{facile de simuler} \\ p(h|v) \rightarrow \end{array} \right.$

Echantillonneur de Gibbs.

Pourquoi ce modèle ?

Thm d'universalité :

$$\sum_v p(v) \log \frac{p(v)}{p_0(v)} \geq 0$$
$$D_{KL} \left(\underset{\substack{\uparrow \\ \text{vrai loi}}}{p(v)}, \underset{\substack{\uparrow \\ \text{loi du RBN}}}{p_0(v)} \right) \leq \epsilon$$

C. Apprentissage d'un RBM.

(7)

Estimer θ à partir de n réalisations

$$x^{(1)}, \dots, x^{(n)} \stackrel{\text{iid}}{\sim} p(v)$$

$$x^{(i)} = (x_1^{(i)}, \dots, x_p^{(i)})$$

\Rightarrow Estimateur du MV

$$\mathcal{L}(x^{(1)}, \dots, x^{(n)}, \theta) = \frac{1}{n} \sum_{i=1}^n \mathcal{L}(x^{(i)}, \theta)$$

$$\text{avec } \mathcal{L}(x; \theta) = p_{\theta}(x)$$

$$= p_{\theta}(v=x)$$

$$= \sum_h p_{\theta}(x, h)$$

$$\text{Maximisons } \log \mathcal{L} = \sum_{i=1}^n \log p_{\theta}(x^{(i)}, \theta)$$

$$\nabla_{\theta} \log \mathcal{L} = \sum_{i=1}^n \nabla_{\theta} \log p_{\theta}(x^{(i)}, \theta)$$

$$\text{Calculons } \nabla_{w_{ij}} \log \mathcal{L}(x; \theta)$$

$$\nabla_{w_{ij}} \log \sum_h p_{\theta}(x, h)$$

$$= \frac{\partial}{\partial w_{ij}} \log \sum_h e^{-E_{\theta}(x, h)} = \log Z_{\theta}$$

$$= \frac{\partial}{\partial w_{ij}} \log \sum_h e^{-E(x, h)} = \log \sum_{v, h} e^{-E(v, h)}$$

$$= \frac{\sum_n \frac{\partial}{\partial w_{ij}} e^{-E(x, h)}}{\sum_h e^{-E(x, h)}} - \frac{\sum_{v, h} \frac{\partial}{\partial w_{ij}} e^{-E(v, h)}}{\sum_{v, h} e^{-E(v, h)}} \quad (8)$$

$$= \frac{\sum_h x_i h_j \left[\frac{e^{-E(x, h)}}{\sum_h e^{-E(x, h)}} \right]}{\sum_h e^{-E(x, h)}} - \frac{\sum_{v, h} v_i h_j \left[\frac{e^{-E(v, h)}}{\sum_{v, h} e^{-E(v, h)}} \right]}{\sum_{v, h} e^{-E(v, h)}}$$

$$= \sum_h x_i h_j p(h|x) - \sum_{v, h} v_i h_j p(v, h) = p(v, h)$$

$$= \sum_{h_j} x_i h_j p(h_j|x) - \sum_{v, h} v_i h_j p(v, h)$$

$$= x_i x p(h_j=1|x) - E(f_{ij}(v, h))$$

$$\text{so } f_{ij}(v, h) = v_i h_j$$

$$E(v_i h_j) = E(\cancel{v_i h_j} \mid \cancel{v, h})$$

$$= E(E(v_i h_j | v))$$

$$= \sum_v v_i \left[\sum_{h_j} h_j p(h_j | v) \right] p(v)$$

$$= E(v_i \cdot p(h_j=1 | v))$$

Approximations $E(v_i p(h_j=1 | v))$ via Gibbs:

$$v^{(0)} = x$$

$$h^{(0)} \sim p(h | v^{(0)})$$

$$v^{(1)} \sim p(v | h^{(0)})$$

$$\Rightarrow \mathbb{E}(v_i | h_j) \approx v_i^{(1)} \cdot p(h_j=1 | v^{(1)})$$

On a donc

$$\frac{\partial}{\partial w_{ij}} \log \mathcal{L}(x; \theta) \approx x_i \cdot p(h_j=1 | x) - v_i^{(1)} \cdot p(h_j=1 | v^{(1)})$$

De même

$$\frac{\partial}{\partial a_i} \log \mathcal{L}(x; \theta) \approx x_i - v_i^{(1)}$$

$$\frac{\partial}{\partial b_j} \log \mathcal{L}(x; \theta) \approx p(h_j=1 | x) - p(h_j=1 | v^{(1)})$$

Algorithmic Contrastive Divergence - 1

Input: Pour une donnée x

$$\begin{array}{ccc} \bullet & W, & a, & b \\ & \uparrow & \uparrow & \uparrow \\ & p \times q & 1 \times p & 1 \times q \end{array}$$

$$v^{(0)} = p(x)$$

$$h^{(0)} \sim p(h | v^{(0)})$$

$$v^{(1)} \sim p(v | h^{(0)})$$

$$\nabla_{w_{ij}} \log \mathcal{L} = x_i p(h_j=1 | x) - v_i^{(1)} p(h_j=1 | v^{(1)})$$

$$\nabla_{a_i} \log \mathcal{L} = v_i^{(0)} - v_i^{(1)}$$

$$\nabla_{b_j} \log \mathcal{L} = p(h_j=1 | v^{(0)}) - p(h_j=1 | v^{(1)})$$

$$w_{ij} \leftarrow w_{ij} + \epsilon \nabla_{w_{ij}} \mathcal{L}$$

(10)

$$a_i \leftarrow a_i + \epsilon \nabla_{a_i} \mathcal{L}$$

$$b_j \leftarrow b_j + \epsilon \nabla_{b_j} \mathcal{L}$$

- Evaluer l'erreur de reconstruction

$$\bullet x \rightarrow p(h|x) \rightarrow p(x | p(h|x))$$

$$x \rightarrow h \rightarrow x'$$

$(x' - x)^2 \rightarrow$ diminue au cours des itérations.

En pratique

$$\bullet \text{Data} = x = \begin{matrix} \updownarrow n \\ \left(\begin{array}{ccccc} x & x & x & x & x \\ x & x & x & x & x \\ x & x & x & x & x \end{array} \right) \\ \leftarrow p \rightarrow \end{matrix}$$

$$\bullet \text{RBM} : \left\{ \begin{array}{ll} \text{RBM} \cdot w & \rightarrow \text{matrice } p \times q \\ \text{RBM} \cdot a & \rightarrow \text{vecteur } 1 \times p \\ \text{RBM} \cdot b & \rightarrow \quad \quad 1 \times q \end{array} \right.$$

$$\bullet \text{Entree-sortie} \left(\underbrace{\text{data}}_{m \times p}, \text{RBM} \right) \rightarrow \text{doit ressortir } \text{data-h} \rightarrow m \times q$$

$$\bullet \text{sortie-entree} \left(\underbrace{\text{data-h}}_{m \times q}, \text{RBM} \right) \rightarrow \text{data-v} \rightarrow m \times p$$

- $\text{Init_RBM}(p, q)$

⑪

- $\text{train_RBM}(x, \text{RBM}, \text{epochs}, \text{learning_rate}, \text{batch_size})$
→ doit retourner RBM entraîné

Écrire le pseudo code de gradient par mini-batch pour entraîner le RBM via CD-1. Boucle for réservée aux epochs et aux batches.

