

# MAINTENANCE PRÉDICTIVE

---

# Plan du cours

- **Introduction**
- **Modélisation statistique des lois de vie**
- **Construction d'indicateurs de santé**
- **Sélection de variables, types de variables et prédiction**
- **Capteurs, analyse de risques, réseaux bayésiens**
- **Examen**


# STATISTIQUES

# Modélisation statistique

- **Rappels:**

- > Les enjeux de la maîtrise de la maintenance :
  - Réduire les coûts, et ce, sous certaines contraintes
- > Vu en TP :
  - Les systèmes tombent en panne selon certaines probabilités
- > L'objectif de cette séance :
  - Quelles modélisations probabilistes adopter ?
  - Comment apprendre ces modèles ?

Défi: nous n'observons que des échantillons de l'ensemble de la population



# Données censurées : savoir utiliser des information partielles

## Données censurées :


- On dit qu'on a une observation **censurée** si la valeur de la mesure qui est faite n'est connue que partiellement.
- Exemple d'application : Modélisation temps de défaillance d'une pièce dans une flotte.
  - On ne connaît pas le temps de défaillance des pièces qui ne sont pas encore tombées en panne.
  - On sait seulement que ce temps de défaillance est supérieur à l'âge actuel de la pièce.

### Trois types de censures

- À droite (suspension en anglais),
- À gauche,
- Par intervalle.

Légende :

- On sait que l'individu est sain
- On ne connaît pas l'âge exact de la défaillance
- × Défaillance
- Censure à droite
- | Censure à gauche



# Données censurées, quelques notations


- Dans la suite, on travaille avec les censure à droite et on note :
  - >  $T_i$  est le temps de défaillance, la date de censure
  - >  $Y_i = \min(T_i, C_i)$  le temps observé
  - >  $\Delta_i = I(T_i \leq C_i)$  un indicateur de censure à droite
- Pour avoir des résultats théoriques:
  - > **Hypothèse** : les censures sont **non informatives**. C.à.d. la censure et le temps de défaillance sont indépendants :

$$T_i \perp C_i$$

- Dans la réalité, la censure peut dépendre du temps.

Légende :

- On sait que l'individu est sain
- On ne connaît pas l'âge exact de la défaillance
- × Défaillance
- Censure à droite
- | Censure à gauche



## Un peu de fiabilité, fonction de survie et taux de défaillance

- Soit  $T$  une variable aléatoire positive appelée temps de défaillance.
- $F(t) := P(T \leq t)$  sa fonction de répartition (c.à.d.  $F(t)$  est la probabilité d'avoir une défaillance avant le temps  $t$ )
- $f(t)$  est sa fonction de densité  $f(t) = F'(t)$
- **Fonction de survie** : probabilité d'être encore en vie à temps  $t$  :

$$S(t) = P(T > t) = 1 - F(t)$$

- **Taux de défaillance instantané** : probabilité de tomber en panne entre  $t$  et  $t+dt$  sachant qu'on est en vie à temps  $t$

$$h(t) = \lim_{dt \rightarrow 0} \frac{P(T < t + dt | T > t)}{dt} = \lim_{dt \rightarrow 0} \frac{F(t + dt) - F(t)}{dt} \times \frac{1}{1 - F(t)} = \frac{f(t)}{1 - F(t)}$$

- Taux de défaillance cumulé :

$$H(t) = \int_0^t h(u) du = -\log(S(t))$$





## Un peu de fiabilité, fonction de survie et taux de défaillance

Expressed by	$S(t)$	$h(t)$
$S(t) =$	—	$\exp\left(-\int_0^t h(s) ds\right)$
$h(t) =$	$-\frac{d}{dt}\ln(S(t))$	—

# Un peu de fiabilité, fonction de survie et taux de défaillance

- Exemple simple : la loi exponentielle
  - > L'équipement vieillit continuellement sans mémoire



# Un peu de fiabilité, les fonctions caractéristiques avec une loi exponentielle

- La fonction de répartition :

$$F(t) = P(T \leq t) = 1 - \exp(-\lambda t)$$

- Fonction de survie :

$$S(t) = P(T > t) = \exp(-\lambda t)$$

- Taux de défaillance instantané :

$$h(t) = \frac{f(t)}{1 - F(t)} = \lambda$$

- Taux de défaillance cumulé :

$$H(t) = \int_0^t h(u) du = \lambda t$$

# ESTIMATIONS PARAMÉTRIQUES

# Maximum de vraisemblance

- Pour les méthodes paramétriques, on va chercher le maximum de vraisemblance pour un jeu de paramètres donné (on veut maximiser la vraisemblance des données)
- La vraisemblance dans la cas général est donnée par :

$$L(t_i, t_j, t_k, t_{Rq}, t_{Lq}; \theta) = \prod_{i=1}^I f_{\theta}(t_i) \prod_{j=1}^J (1 - F_{\theta}(t_j)) \prod_{k=1}^K F_{\theta}(t_k) \prod_{q=1}^Q [F_{\theta}(t_{Rq}) - F_{\theta}(t_{Lq})]$$

Défaillances ; Censures à droite ; Censures à gauche ; Censures par intervalle ;  
 « Probabilité Probabilité d'être Probabilité d'être Probabilité d'être  
 instantanée » défaillant après  $t_j$ , défaillant avant  $t_k$ , défaillant entre  $t_{Rq}$  et  $t_{Lq}$ ,  
 d'être sachant que  $j$  est sachant que  $k$  est sachant que  $q$  est  
 défaillant à  $t_i$  sain à  $t_j$  défaillant à  $t_k$  défaillant entre  $t_{Rq}$  et  $t_{Lq}$

- On cherche ensuite le paramètre qui maximise la vraisemblance.
- Pour des raisons numériques, on maximise souvent la log-vraisemblance

## Maximum de vraisemblance avec une loi exponentielle

- Application dans le cas d'une loi exponentielle avec des données censurées à droite ou complètes :

➤ Expression de la loi :

$$f(t) = \lambda \cdot \exp(-\lambda t), F(t) = 1 - \exp(-\lambda t)$$

➤ Echantillon  $(Y_i, \delta_i)$  où  $\delta_i = 1$  si défaillance,  $\delta_i = 0$  sinon, on peut estimer  $\lambda$  directement :

$$\hat{\lambda} = \frac{\sum_{i=1}^N \delta_i}{\sum_{i=1}^N Y_i} = \frac{\text{Nombre de défaillances}}{\text{Temps cumulé de fonctionnement}} = \frac{d}{T_{cum}}$$

## Maximum de vraisemblance avec une loi exponentielle

- Application dans le cas d'une loi exponentielle avec des données censurées à droite ou complètes :
  - Expression de la loi :  $f(t) = \lambda \cdot \exp(-\lambda t)$ ,  $F(t) = 1 - \exp(-\lambda t)$
  - Echantillon  $(Y_i, \delta_i)$  où  $\delta_i = 1$  si défaillance,  $\delta_i = 0$  sinon, on peut estimer  $\lambda$  directement :

$$\hat{\lambda} = \frac{\sum_{i=1}^N \delta_i}{\sum_{i=1}^N Y_i} = \frac{\text{Nombre de défaillances}}{\text{Temps cumulé de fonctionnement}} = \frac{d}{T_{cum}}$$

- En effet →

$$L(t_i, t_j, t_k, t_{Rq}, t_{Lq}; \theta) = \prod_{i=1}^I f_{\theta}(t_i) \prod_{j=1}^J (1 - F_{\theta}(t_j)) \prod_{k=1}^K F_{\theta}(t_k) \prod_{q=1}^Q [F_{\theta}(t_{Rq}) - F_{\theta}(t_{Lq})]$$

## Maximum de vraisemblance avec une loi exponentielle

- Application dans le cas d'une loi exponentielle avec des données censurées à droite ou complètes :

> Expression de la loi :  $f(t) = \lambda \cdot \exp(-\lambda t)$ ,  $F(t) = 1 - \exp(-\lambda t)$

> Echantillon  $(Y_i, \delta_i)$  où  $\delta_i = 1$  si défaillance,  $\delta_i = 0$  sinon, on peut estimer  $\lambda$  directement :

$$\hat{\lambda} = \frac{\sum_{i=1}^N \delta_i}{\sum_{i=1}^N T_i} = \frac{\text{Nombre de défaillances}}{\text{Temps cumulé de fonctionnement}} = \frac{d}{T_{cum}}$$

- En effet →

$$L(t_i, t_j, t_k, t_{Rq}, t_{Lq}; \theta) = \prod_{i=1}^I f_{\theta}(t_i) \prod_{j=1}^J (1 - F_{\theta}(t_j))$$

$$L(T_i; \lambda) = \prod_i f(T_i)^{\delta_i} \times (1 - F(T_i))^{1-\delta_i} = \prod_{i, \delta_i=1} \lambda \cdot \exp(-\lambda T_i) \cdot \prod_{i, \delta_i=0} \exp(-\lambda T_i) = \lambda^d \cdot \exp(-\lambda T_{cum})$$

$$\frac{\partial L}{\partial \lambda} = -d\lambda^{d-1} \cdot \exp(-\lambda T_{cum}) + T_{cum}\lambda^d \cdot \exp(-\lambda T_{cum}) \text{ ou en log : } \frac{\partial \log(L)}{\partial \lambda} = \frac{d}{\lambda} - T_{cum}$$

$$\frac{\partial^2 \log(L)}{\partial \lambda^2} = \frac{d}{\lambda^2} > 0$$



# Maximum de vraisemblance avec une loi de Weibull

## ■ Application dans le cas d'une loi de Weibull avec des données complètes :

➤ Le modèle exponentiel est souvent trop simple

## ■ Modèle de Weibull

➤  $f(t, \lambda, k) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} e^{-\left(\frac{t}{\lambda}\right)^k}$


➤  $k < 1$ : le taux de panne diminue avec le temps

➤  $k = 1$ : le taux de panne constant dans le temps

➤  $k > 1$ : le taux de panne augmente avec le temps

➤  $k$  est le paramètre de forme

➤  $\lambda$  est le paramètre d'échelle



# Maximum de vraisemblance avec une loi de Weibull


## ■ Détermination des coefficients

### ➤ Méthode “graphique”

- Calcul des probabilités cumulées de pannes  $F(t)$
- On trace  $\log(t) = \log(-\log(1-F(t)))$
- On a :
  - ♦  $F(x) = 1 - e^{-\left(\frac{x}{\lambda}\right)^k}$
  - ♦  $-\ln(1 - F(x)) = \left(\frac{x}{\lambda}\right)^k$
  - ♦  $\ln(-\ln(1 - F(x))) = k \ln(x) - k \ln \lambda$
- On en déduit facilement  $k$  et  $\lambda$

### ➤ Méthode par maximum de vraisemblance

- Connaissant  $k$ :
  - ♦  $\lambda^k = \frac{1}{n} \sum_i t_i^k$
- Pour  $k$ :
  - ♦  $0 = \frac{\sum_i t_i^k \ln(t_i)}{\sum_i t_i^k} - \frac{1}{k} - \frac{1}{n} \sum_i \ln(t_i)$
  - ♦ Généralement, cette equation est résolue numériquement



# ESTIMATIONS NON PARAMÉTRIQUES

## Estimation non paramétrique

- **Objectif** : estimer de manière non paramétrique des fonctions représentatives de la distribution de nos défaillances à partir d'un échantillon de données censurées

## Estimation non paramétrique : Kaplan-Meier

Samples	I	II
Initial numbers	100	1000
Deaths in first year of age	<u>70</u>	<u>750</u>
One-year survivors	30	250
Deaths in second year of age	<u>15</u>	
Two-year survivors	15	

- Quelle est la probabilité de survivre 1 an ?

## Estimation non paramétrique : Kaplan-Meier

Samples	I	II
Initial numbers	100	1000
Deaths in first year of age	<u>70</u>	<u>750</u>
One-year survivors	30	250
Deaths in second year of age	<u>15</u>	
Two-year survivors	15	

- Quelle est la probabilité de survivre 1 an ?

$$\hat{P}(1) = P^*(1) = (30 + 250)/(100 + 1000) = .255$$

## Estimation non paramétrique : Kaplan-Meier

Samples	I	II
Initial numbers	100	1000
Deaths in first year of age	<u>70</u>	<u>750</u>
One-year survivors	30	250
Deaths in second year of age	<u>15</u>	
Two-year survivors	15	

- Quelle est la probabilité de survivre 1 an ?

$$\hat{P}(1) = P^*(1) = (30 + 250)/(100 + 1000) = .255$$

- Deux ans ?

## Estimation non paramétrique : Kaplan-Meier

Samples	I	II
Initial numbers	100	1000
Deaths in first year of age	<u>70</u>	<u>750</u>
One-year survivors	30	250
Deaths in second year of age	<u>15</u>	
Two-year survivors	15	

$$\hat{P}(1) = P^*(1) = (30 + 250)/(100 + 1000) = .255$$

$$\hat{P}(2)/\hat{P}(1) = 15/30 = 0.50,$$

$$\hat{P}(2) = 0.255 \times 0.50 = 0.127,$$



## Estimation non paramétrique : Kaplan-Meier

$t_2 > t_1$  : deux temps de défaillance successifs

$$\begin{aligned}\tilde{S}(t_2) &= P(T > t_2) = P(T > t_2 \wedge T > t_1) \\ &= P(T > t_2 | T > t_1) \times P(T > t_1) = \left(1 - \frac{d_2}{n_2}\right) \times S(t_1)\end{aligned}$$

◆  $d_2$  : nombre de défaillances dans le temps  $t_2$

◆  $n_2$  : nombre d'individus à risque à  $t_2$ , (c.à.d.  $k$  tels que  $y_k \geq t_2$ )

## Estimation non paramétrique : Kaplan-Meier

- Estimateur de **Kaplan-Meier** : estimateur non paramétrique de la fonction de survie
  - >  $\tilde{S}(t) = \prod_{t_i < t} \left(1 - \frac{d_i}{n_i}\right)$
  - >  $d_i$  : nombre de défaillances dans le temps  $t_i$
  - >  $n_i$  : nombre d'individus à risque dans le temps  $t_i$ , (c.à.d.  $k$  tels que  $y_k \geq t_i$ )
- Estimateur de Kaplan-Meier = Estimateur de maximum de vraisemblance sous hypothèses de régularités → on peut construire la variance de l'estimateur et des intervalles de confiance

# Estimation non paramétrique : Kaplan-Meier

- Example:

	Indicateur de défaillance
6	1
19	1
32	1
42	1
42	1
43	0
94	1
126	0
169	0
207	1

	Indicateur de défaillance
211	0
227	0
253	1
255	0
270	0
310	0
316	0
335	0
346	0

Source exemple : Gilbert Colletaz, note de cours

## Estimation non paramétrique : Kaplan-Meier

6, 19, 32, 42, 42, 43\*, 94, 126\*, 169\*, 207, 211\*, 227\*, 253, 255\*, 270\*, 310\*, 316\*, 335\*, 346\*


On obtient alors :

$t_i$	$d_i$	$n_i$	$1 - d_i/n_i$	$\hat{S}(t_i)$	$\hat{F}(t_i) = 1 - \hat{S}(t_i)$
0	0	19	1	1	0
6	1	19	0.947	0.947	0.053
19	1	18	0.944	0.895	0.105
32	1	17	0.941	0.842	0.158
42	2	16	0.875	0.737	0.263
94	1	13	0.923	0.680	0.320
207	1	10	0.90	0.612	0.388
253	1	7	0.957	0.525	0.475



## Estimation non paramétrique : Kaplan-Meier

6, 19, 32, 42, 42, 43\*, 94, 126\*, 169\*, 207, 211\*, 227\*, 253, 255\*, 270\*, 310\*, 316\*, 335\*, 346\*



## Estimation non paramétrique : Nelson-Aalen

- Estimateur de **Nelson-Aalen** : estimateur non paramétrique du taux de défaillance cumulé.
  - $\tilde{H}(t) = \sum_{t_i < t} \frac{d_i}{n_i}$
  - $d_i$  : Nombre de défaillances dans  $t_i$
  - $n_i$  : Nombre d'individus à risque dans  $t_i$
- Intuition :
  - $d_i/n_i$  est un estimateur du taux de défaillance instantané

## Estimation non paramétrique : Autres


- D'autres estimateurs :
  - > Méthode de Johnson sur les rangs médians ou moyen
  - > Estimateur de Fleming-Harrington
  - > Estimateur de Breslow...

# INFLUENCES



## Influences

- Est-ce raisonnable de considérer que des systèmes produits de manière identique ont tous la même probabilité de défaillance ?



## **Certains modèles incorporent des covariates/features**

- Cox proportional hazards model
- Aalen's additive model
- Weibull Accelerated Failure time
- Random Survival Forest
- Gradient boosting Cox log partial likelihood loss
- DeepSurv

# Cox Proportional Hazards Model

## ▪ Les covariates

- Features qui représentent la présence ou l'absence d'un phénomène
- Ex: fumer / ne pas fumer faire du sport / ne pas faire du sport, etc...

## ▪ Equation de la loi de vie :

- $\lambda(t, X_0, \dots, X_n) = \lambda_0(t) \exp(\sum_{i=1..n} \beta_i X_i)$  (taux de défaillance instantanée)
- $\lambda_0$ 
  - le **risque de base**
  - Il dépend du temps
  - il est généralement non estimé (car on veut étudier le rapport entre les variables) → semi-paramétrique
- $\exp(\sum_{i=1..n} \beta_i X_i)$ 
  - Dépend uniquement des covariates
  - Ne dépend pas du temps (modèle de Cox simple)

## ▪ Risques proportionnels → comparaison de deux individus

- Avec 2 individus qui varient uniquement sur le covariate  $k$ :

$$- \frac{\lambda(t, I_1)}{\lambda(t, I_2)} = \frac{\lambda_0(t) (\exp(\sum_{i \neq k} \beta_i X_i + 1 \cdot \beta_k))}{\lambda_0(t) (\exp(\sum_{i \neq k} \beta_i X_i + 0 \cdot \beta_k))} = \exp(\beta_k)$$


## ▪ Les X font varier les risques

# Accelerated Failure Time

## ■ Principe

- > Hypothèse : les facteurs influents accélèrent ou ralentissent le temps avant événement
- > Le modèle devient donc :
  - $\lambda(t|X) = \exp(-\beta x) \lambda_0(\exp(-\beta x) t)$
  - Soit  $S(t|X) = S_0(\exp(-\beta x) t)$ , avec  $S_0$  une fonction de survie quelconque
- > On peut aussi l'écrire ainsi ( $T$  le temps de survie):
  - $\log(T) = \beta x + \epsilon$
  - $\epsilon$  suivra une distribution qui changera la forme de la fonction de survie de  $T$
- > Les hypothèses :
  - On connaît  $S_0$
  - Les  $X_i$  ont une interaction linéaire et indépendante
- > Ici, on agit sur le temps et pas sur le risque

# Accelerated Failure Time vs Proportional Hazard



## ▪ DeepSurv est une amélioration du modèle de Cox

➤  $\lambda(t, X_0, \dots, X_n) = \lambda_0(t) \exp(\sum_{i=1..n} \beta_i X_i)$  devient :

➤  $\lambda(t, X_0, \dots, X_n) = \lambda_0(t) \exp(h_\theta(X_i))$

➤ Où  $h_\theta$  est un réseau de neurones

➤ La fonction de coût est adaptée :

$$l(\theta) := - \sum_{i: E_i=1} \left( \hat{h}_\theta(x_i) - \log \sum_{j \in \mathcal{R}(T_i)} e^{\hat{h}_\theta(x_j)} \right).$$

➤ Comparaison de deux traitements différents :

$$\text{rec}_{ij}(x) = \log \left( \frac{\lambda(t; x | \tau = i)}{\lambda(t; x | \tau = j)} \right) = \log \left( \frac{\lambda_0(t) \cdot e^{h_i(x)}}{\lambda_0(t) \cdot e^{h_j(x)}} \right) = h_i(x) - h_j(x).$$

# Modèle additif d'Aalen

## ■ Principe

- > Le modèle de Cox fait l'hypothèse que l'influence des covariables ne change pas selon le temps
- > Le modèle additif d'Aalen fait une proposition différente :

$$\lambda(t) = (\beta_0) + \sum \beta_i(t)x_i$$

- > Soit  $N(t)$  le nombre d'événement jusqu'à  $t$
- > On doit introduire l'indicateur de risque  $\delta_i$ , tel que  $\delta_i = 1$  si  $X_i$  est à risque, 0 sinon (comme pour Kaplan-Meier)
- > On pose  $X(t) = (\delta_0 X_0(t), \dots, \delta_n X_n(t))$
- > On a alors :  $\lambda(t) = X'(t)\beta(t)$
- > On a  $\Delta N(t) = \Delta M(t) + \lambda(t)$  : la différence des états entre  $t$  et  $t-1$  dépend d'une certaine quantité  $M$  et de  $\lambda$ .
- > Ici je passe la quantité  $\Delta M$ , (qui veut peut regarder [Shrinkage Estimation for Aalen's Additive Model \(uwindsor.ca\)](http://uwindsor.ca)), mais il se trouve que  $E(M) = 0$ , donc on peut utiliser une regression aux moindres carrés pour trouver les  $\beta$ , qui vont valoir :

$$\beta(t) = X^{-1}(t)\Delta N(t)$$



# Random Survival Forest

## ■ Principe

- > Même chose que les Random Forest classiques, mais avec des « survival tree »
- > Le survival tree :
  - Couper selon les covariates (comme les arbres, ça peut être sur une coordonnée, plusieurs, toutes, etc..)
  - Critère de découpe
    - ♦ Le plus courant : C-index
    - ♦ Il en existe d'autres : L1 splitting, AUC splitting, Maximally selected rank splitting

## ■ Le Concordance-Index:

- >  $C - index = \frac{\sum_{i,j} I(t_i > t_j) I(\hat{t}_i > \hat{t}_j) \delta_j}{\sum_{i,j} I(t_i > t_j) \delta_j}$
- >  $\delta_j$  vaut 0 si on la variable est censurée

WANG, Hong et LI, Gang. A selective review on random survival forests for high dimensional data. *Quantitative bio-science*, 2017, vol. 36, no 2, p. 85.

# LES MÉTRIQUES

# Mesurer la performance des méthodes

- **Comment mesurer la performance de nos algorithmes, alors que la vérité terrain est censurée ?**

- > On a l'habitude d'utiliser la RMSE (Root Mean Square Error)
- > On a prédit/modéliser des distributions, et non des prédictions uniques pour chaque sample
- > De plus, quand les données sont censurées, cette mesure est impossible sans adaptation !

- **Exemple simple:**

- > La loi de défaillance suit une loi de Weibull
- > On apprend la loi
- > Comment faire une prédiction ?
  - Moyenne ?
  - Médiane ?
- > Dans tous les cas, on aura un résidu incompressible, même si notre loi apprise correspond parfaitement au phénomène sous-jacent
- > Enfin, même en prédisant la médiane, dans le cas où la vérité terrain est censurée, on ne sait pas comment calculer la RMSE avec un point inconnu
- > Il faut donc raisonner sur tout le dataset, et non sample par sample

## Mesurer la performance des méthodes

- **Le Concordance-Index (qu'on a vu dans les slides précédents):**

- > 
$$C_{index} = \frac{\sum_{i,j} I(t_i > t_j) I(\hat{t}_i > \hat{t}_j) \delta_j}{\sum_{i,j} I(t_i > t_j) \delta_j}$$

- >  $\delta_j$  vaut 0 si on la variable est censurée

- > Le principe est de classer au mieux les paires

- > 1 est un score parfait

- > 0,5 signifie qu'on ne classe pas mieux que le hasard

- > Le défaut évident :

- Si on fait d'énormes erreurs, mais que les échantillons sont bien classés, on a un score de 1

# Mesurer la performance des méthodes

## ■ Le Brier Score

- Prévu pour comparer des distributions par rapport à des tirages d'événements
- Le score :  $\frac{1}{n} \sum_{i=0}^{n-1} (o_i - f_i)^2$
- où :
  - $n$  est le nombre d'événements
  - $f_i$  est la prévision (une probabilité de 0 à 1) pour le  $i$ -ème événement
  - $o_i$  est le résultat (0 ou 1) du  $i$ -ème événement
- Exemple :
  - Comment comparer deux modèles de vainqueur pour la présidentielle ?
  - Une fois l'élection passée, on compare le pourcentage obtenu avec le résultat, le modèle le plus proche a un meilleur score

# Mesurer la performance des méthodes

## ▪ Le Brier Score temporel

>  $BS(t) := \frac{1}{n} \sum_{i=0}^{n-1} \left( I(y_i > t) - \hat{S}(t|x_i) \right)^2$

> où :

- $n$  est le nombre d'événements
- $I(\cdot)$  est la fonction indicatrice
- $\hat{S}(t|x)$  est la probabilité prédite d'un modèle de rester sans événement jusqu'à l'instant  $t$  pour le vecteur de caractéristiques  $x$

> Exemple :

- Mon modèle donne une probabilité pour chaque temps que l'événement arrive, je l'évalue en  $t$
- On compare cela au fait que l'événement ait eu lieu  $I(y > t)$

# Mesurer la performance des méthodes

## ▪ Le Brier Score temporel avec données censurées

➤  $BS(t) := \frac{1}{n} \sum_{i=0}^{n-1} \left( I(y_i > t) - \hat{S}(t|x_i) \right)^2$  peut se réécrire

$$BS(t) := \frac{1}{n} \sum_{i=0}^{n-1} I(y_i \leq t) \left( 0 - \hat{S}(t|x_i) \right)^2 + I(y_i > t) \left( 1 - \hat{S}(t|x_i) \right)^2$$

➤ où :

- $n$  est le nombre d'événements
- $I(\cdot)$  est la fonction indicatrice
- $\hat{S}(t|x)$  est la probabilité prédite d'un modèle de rester sans événement jusqu'à l'instant  $t$  pour le vecteur de caractéristiques  $x$  (i.e. probabilité d'être encore en vie)

# Mesurer la performance des méthodes

## ■ Le Brier Score temporel avec données censurées

>  $BS(t) := \frac{1}{n} \sum_{i=0}^{n-1} \left( I(y_i > t) - \hat{S}(t|x_i) \right)^2$  peut se réécrire  $BS(t) := \frac{1}{n} \sum_{i=0}^{n-1} I(y_i \leq t) \left( 0 - \hat{S}(t|x_i) \right)^2 + I(y_i > t) \left( 1 - \hat{S}(t|x_i) \right)^2$

> On va utiliser cette formalisation pour faire intervenir la censure

> Soit  $\hat{G}(t) := P(C > t)$  l'estimateur de la fonction de survie conditionnelle des temps de censure calculés selon la méthode de Kaplan-Meier, où C est le temps de censure (et non l'événement!)

>  $BS^c(t) := \frac{1}{n} \sum_{i=0}^{n-1} I(y_i \leq t \wedge \delta_i = 1) \frac{\left( 0 - \hat{S}(t|x_i) \right)^2}{\hat{G}(y_i)} + I(y_i > t) \frac{\left( 1 - \hat{S}(t|x_i) \right)^2}{\hat{G}(t)},$

> où :

- $n$  est le nombre d'événements
- $I(\cdot)$  est la fonction indicatrice
- $\hat{S}(t|x)$  est la probabilité prédite d'un modèle de rester sans événement jusqu'à l'instant  $t$  pour le vecteur de caractéristiques  $x$  (i.e. probabilité d'être encore en vie)
- $1/\hat{G}(\cdot)$  est un poids de pondération qui utilise l'estimation de la probabilité de censure : on peut voir cette partie comme une pondération par l'inverse de la probabilité de censure pour ce temps -> grande probabilité d'être censuré = peu de fiabilité sur l'erreur, petite probabilité d'être censuré -> grande fiabilité de l'erreur



# Mesurer la performance des méthodes

- **Le Brier Score temporel avec données censurées intégré**

- Une fois le Brier Score calculé, on va tout simplement l'intégrer sur tous les temps.
- Ce score est calculé par une approximation trapézoïdale (que ce soit censuré ou non censuré)
- $IBS = \int_{t_1}^{t_{max}} BS(t) dw(t)$

Source : pysurvival documentation

# CONCLUSIONS

# Conclusions

## ▪ Méthode statistiques

- > On veut modéliser les probabilités de pannes pour un système
- > On dispose d'échantillons pour le faire
- > Ces échantillons peuvent être censurés (le plus souvent à droite)

## ▪ Les outils pour le faire

- > Loi paramétriques
- > Loi non paramétriques

## ▪ Influences

- > Modèles spécifiques
- > On peut vouloir uniquement l'analyse relative
- > Quelques exemples emblématiques ont été passés en revue

## ▪ Métriques

- > Concordance Index
- > Brier Scores